Année Universitaire 2026-2027

RAPPORT MINI PROJET FSY

Réalisé par:

Blanche ZONANG & Christopher KOUTOUA

Université de Rennes 1
MASTER 2 MIAGE DABI PARCOUS CLASSIQUE

16/10/2026

SOMMAIRE

Partie 1: Préparation des données et sélection des attributs

I. Chargement et compréhension des données. 3
II. Nettoyage des données 3
III. Préparation des informations temporelles 3
IV. Analyse Statistique 3
1. Variables numériques 3
2. Variables catégorielles 4
V. Vérification et visualisation des coordonnées géographiques 4
VI. Sélection des attributs pour le clustering **5**

Partie 2: Découverte de points d'intérêt par clustering

I. Recherche du nombre de clusters 5
II. Visualisation des clusters 5
III. Interprétation et discussion des résultats 6
IV. Apports pour Rennes Métropole **6**

Partie 3: Description des points d'intérêt grâce à la fouilles de motifs ensembliste

Partie 1 : Préparation des données et sélection des attributs.

I. Chargement et compréhension des données.

Le jeu de données provient de Flickr et est importé dans KNIME via le nœud CSV Reader. Il contient 54 800 lignes et 15 attributs. Chaque observation est associée à une photographie et comporte les informations suivantes : l'identifiant de la photographie (id_photo), l'identifiant du photographe (id_photographer), les coordonnées GPS de la photographie (lat et long), la date de prise de vue (date_taken_time), les tags (tags) et le titre (title). Nous distinguons plusieurs catégories de variables.

- Les variables numériques décrivant la position géographique : lat et long
- les variables numériques qui sont des identifiants : id_photo
- les variables textuelles : id_photographer, tags, title
- les variables temporelles : date_taken_*

II. Nettoyage des données

La première remarque que nous faisons est la présence de nombreuses répétitions dans le fichier. Le nœud Duplicate Row Filter est utilisé pour supprimer ces doublons. La suppression des doublons repose sur l'idée suivante : deux lignes qui possèdent le même identifiant de photographie et le même identifiant de photographe renvoient à une même photographie. Après cette opération, le nombre d'observations passe de 54 800 à 4 195 photographies c'est près de 92% des lignes du fichier initial qui correspondaient à des répétitions.

III. Préparation des informations temporelles

La colonne date_taken_time contient la date et l'heure dans une même chaîne de caractères. Pour faciliter les analyses temporelles, cette colonne est séparée grâce au nœud Cell Splitter en utilisant le caractère T comme séparateur. La première partie est convertie en type Date et la deuxième partie est convertie en type Time.
Cela peut nous être utile pour une étude des horaires auxquels l'activité photographique est plus importante.

IV. Analyse Statistique

1. Variables numériques

Le nœud Statistics View permet d'observer les valeurs manquantes, le nombre de valeurs distinctes, le minimum, le maximum, les quartiles, la médiane, la moyenne et l'écart-type. Ce traitement est appliqué aux coordonnées géographiques ainsi qu'aux différentes variables temporelles. Il n'y a aucune valeur manquante et les coordonnées obtenues sont comprises entre : 48,043928 et 48,181647 pour la latitude et -1,782224 et -1,572418 pour la longitude.

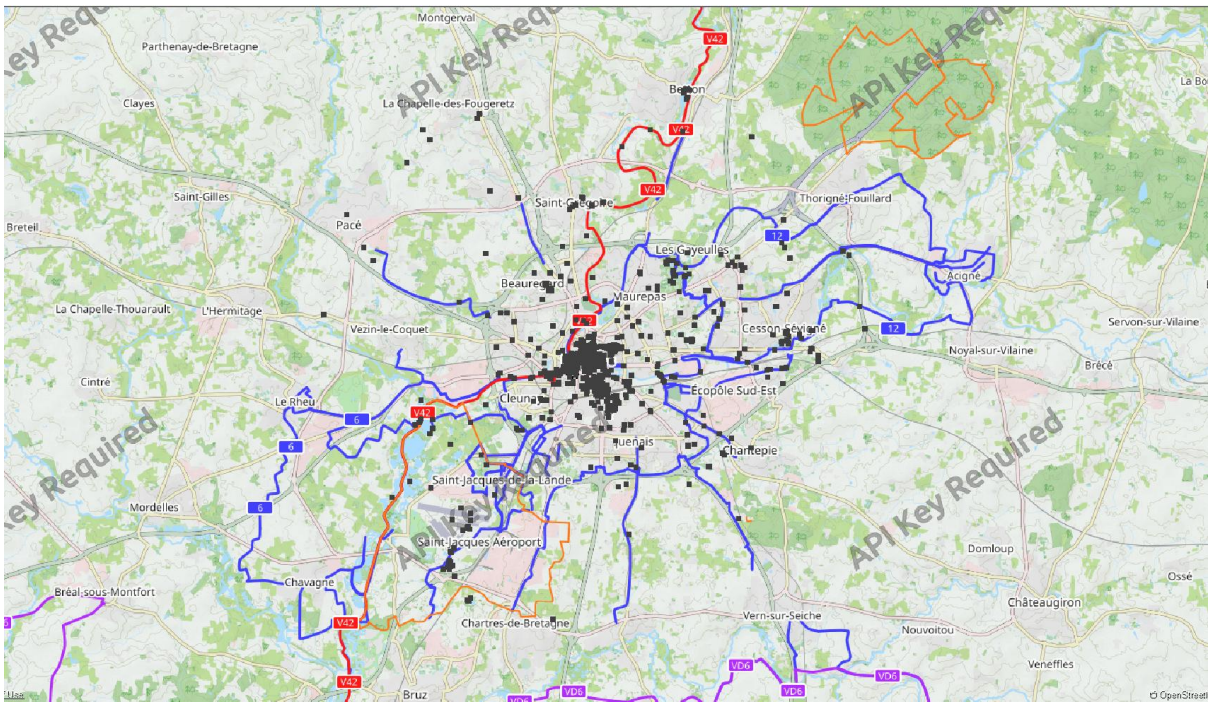
Ces valeurs sont compatibles avec une zone géographique située autour de Rennes et ne présentent pas d'anomalie manifeste telle qu'une latitude ou une longitude impossible.

2. Variables catégorielles

Concernant les variables catégorielles, les statistiques retenues sont principalement le nombre valeurs manquantes, le nombre de valeurs distinctes et les valeurs les plus fréquentes. L'analyse nous montre une forte concentration des contributions. Les deux photographes les plus actifs représentent ensemble 69,4% des 4 195 photographies uniques. Nous pouvons donc affirmer qu'une forte densité de photographies dans une zone ne signifie pas nécessairement qu'un grand nombre de personnes différentes ont fréquenté cet endroit.

V. Vérification et visualisation des coordonnées géographiques

Dans cette partie nous contrôlons la cohérence spatiale avec le nœud Geo-Coordinate Row Filter et visualisons avec le nœud OSM Map View.



La visualisation montre une forte concentration des observations dans le centre de Rennes et des photographies plus dispersées dans les zones périphériques. Grâce à cette visualisation, nous vérifions visuellement les positions. Aucune coordonnée n'est isolée ou incohérente.

VI. Sélection des attributs pour le clustering

La dernière étape de la préparation des données consiste à sélectionner les variables pertinentes pour le clustering. Notre objectif étant de détecter des points d'intérêt à partir de la proximité géographique des photographies, seules les colonnes lat et long sont retenues par un nœud Column Filter.

Partie 2 : Découverte de points d'intérêt par clustering

Après la préparation des données, nous passons à l'étape du clustering pour la découverte des points d'intérêts.
Les variables pertinentes pour réaliser le clustering sont les coordonnées géographiques latitude (lat) et longitude (long).

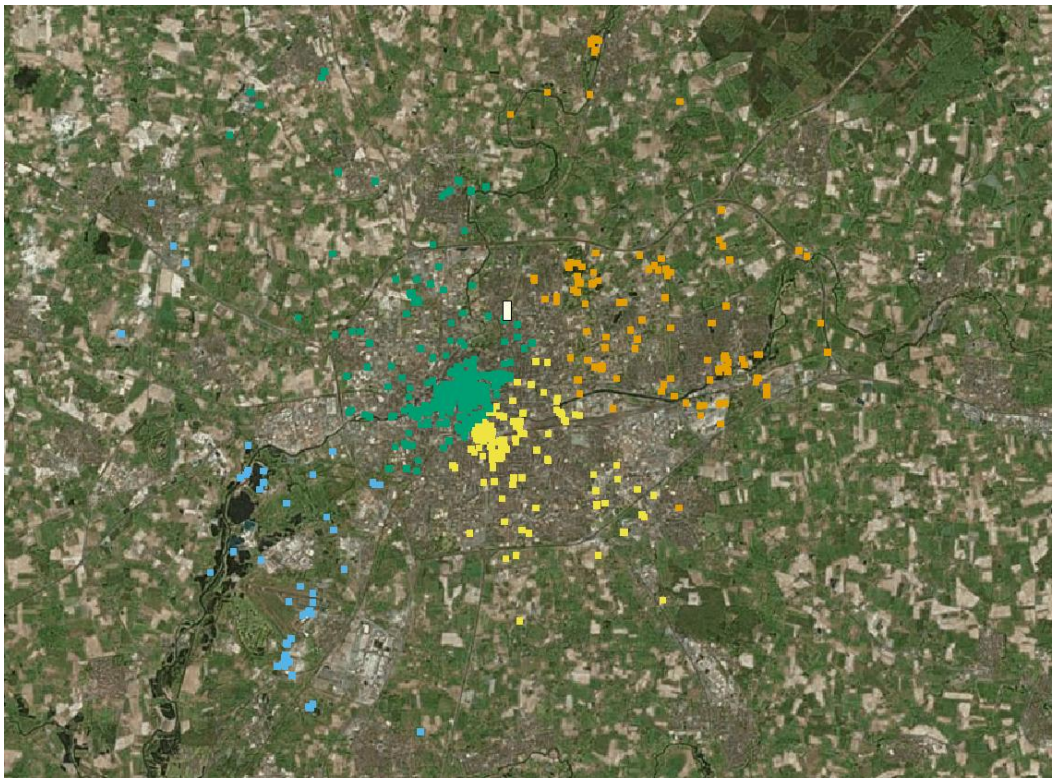
I. Recherche du nombre de clusters

La difficulté rencontrée dans cette phase de recherche est la rigidité du nœud k-means. En effet, le nombre de groupes k doit être défini avant l'apprentissage. Pour palier à ce problème, nous avons découvert lors de nos recherches sur le KNIME COMMUNITY HUB un composant appelé Optimized K-Means (Silhouette Coefficient).

Voici son fonctionnement: une recherche est réalisée pour plusieurs valeurs de k (2 à 10) avec un pas de 1. Pour chaque valeur de k on évalue la qualité du clustering obtenu en calculant le coefficient de silhouette. Un coefficient de silhouette proche de 1 traduit une partition où les observations sont bien regroupées à l'intérieu de leur cluster et suffisamment éloignées des autres groupes. A l'inverse, un coefficient proche de 0 traduit davantage de chevauchement entre clusters.

Parmi les valeurs testées, k = 4 fournit le meilleur coefficient de silhouette. Nous retenons donc 4 clusters pour la suite de cette analyse.

II. Visualisation des clusters



III. Interprétation et discussion des résultats

Les quatre clusters obtenus peuvent être considérés comme des zones candidates de points d'intérêt car ils regroupent des photographies proches. Nous observons également une concentration d'activité photographique dans le centre de Rennes Cependant, nous ne pouvons pas affirmer avec certitude que ces zones sont des points d'intérêt. Un même utilisateur peut publier de nombreuses photographies d'un même secteur et augmenter ainsi artificiellement sa densité.

IV. Apports pour Rennes Métropole

L'analyse effectuée permet de mettre en évidence les zones à forte activité photographique de Rennes Métropole. Ces zones pouraient constituer des points d'intérêt. Ces informations peuvent être utilisées pour améliorer les transports en commun, proposer des sites touristiques aux touristes ou encore mener des actions de valorisation de certains espaces urbains.

Partie 3: Description des points d'intérêt grâce à la fouilles de motifs ensembliste.

Dans cette partie, nous avons appliqué la chaîne de traitements proposée.
Comme minimum support nous avons retenu la valeur 10% pour chaque cluster.
Voici les résultats obtenus:

- **cluster_0**

Les motifs fréquents sont : "championnat", "départemental", "bretagne" et "ren". Il semblerait que cluster décrit une zone caractérisée par des compéitions sportives.

- **cluster_1**

Le motif dominant dans ce cluster est "rennais". C'est un cluster très homogène associé à un événement ponctuel, La Rennaise 2017. Une très grande partie des photos portent le titre "La Rennaise 2017".

- **cluster_2**

Il contient plus de 300 motifs fréquents. Nous retrouvons des motifs comme: "renn","street","art","asphalt","bitum","graph","chantier","building". Il peut être interprété comme une zone urbaine caractérisée par la rue, le street art, les travaux urbains.

- **cluster_3**

Il est caractérisé par les motifs: "apigné", "étang", "sejourne","ren". Il peut être interprété comme une zone périphérique associée aux étangs d'Apigné, à l'environnement naturel.